

Sistem za preporuku filmova

Član tima: Luka Nikolić SW64/2017

Motivacija

Pronaći film koji nam se sviđa u današnje vreme sa izobiljem sadržaja je monumentalan zahvat, pogotovo za filmofile koji su već pogledali sve poznatije naslove. Potrebno je razviti aplikaciju koja će korisniku, na osnovu njegovih preferencija i istorije pregleda, predložiti najprikladnije filmove.

Opis problema

Problem predlaganja sadržaja su pokušale da reše mnoge kompanije i platforme. Netflix je razvio kompleksan machine learning algoritam sa velikim brojem parametara i podataka [1]. Koristeći Poasonovu korelaciju između filmova i regresione modele, određuju jedinstvene predloge za svakog korisnika. Sa druge strane, rad [2] uvodi rule based model koji predviđa preferencije grupe korisnika na osnovu njihovih istorija i ocena.

Sistem za preporuku filmova opisan u ovom radu koristi Drools rule engine i, pored korisnikovih omiljenih žanrova i istorije ocenjivanja, uzima u obzir ključne reči koje dublje opisuju filmove. Ključne reči su slobodniji pojam koji preciznije opisuje atmosferu, iskustvo i osećanja tokom gledanja filma nego žanr sam po sebi, pa se koriste kao osnovni gradivni blok sistema rezonovanja.

Metodologija rada

Sistemu je potrebna kolekcija filmova prikupljena sa online baza podataka filmova, gde svaki film sadrži žanrove, ključne reči, glumce i reditelja. Rule engine iz ovih podataka gradi radnu memoriju u kojoj se izvršava rezonovanje.

Entiteti domena

- **User** — korisnik aplikacije: lični podaci, sviđanja, nesviđanja, pogledani filmovi, watchlist, recenzije, omiljene ključne reči, omiljeni žanrovi.
- **Movie** — film iz baze: režiser, glumci, trajanje, prosečna ocena, žanrovi, ključne reči.
- **Genre / Keyword** — žanr, odnosno ključna reč, kao odvojeni entiteti povezani sa filmom.
- **Review** — recenzija koju je korisnik ostavio za film, sa ocenom na skali 1–10.

Činjenice u radnoj memoriji (Drools facts)

Za rezonovanje se ovi entiteti preslikavaju u posebne činjenice koje rule engine koristi:

- **UserFact** — korisnikov id, ime, prezime, skupovi id-jeva lajkovanih, nelajkovanih, pogledanih i watchlistovanih filmova, kao i eksplicitno unete omiljene ključne reči i žanrovi.
- **MovieFact** — id filma, naslov, njegove ključne reči, žanrovi, tmdb ocena i prosečna ocena recenzija.
- **ReviewFact** — korisnikov id, id filma i ocena recenzije (1–10).
- **KeywordInteraction** — međurezultat sloja A1: pojedinačna interakcija korisnika sa ključnom reči, tipa LIKE, DISLIKE ili REVIEW.
- **KeywordStats** — agregirana težina jedne ključne reči za korisnika, rezultat sloja A2.
- **MovieStats** — agregirana ocena jednog filma na osnovu njegovih ključnih reči, rezultat sloja A3.

- **Recommendation** — konačan predlog: film i njegov ukupan score, rezultat sloja A4.

Ulaz i izlaz sistema

Ulaz u sistem je jedna ili obe od sledećih stvari:

1. **Istorija korisnika** — lajkovani i nelajkovani filmovi, pogledani filmovi, watchlist i recenzije — ako korisnik uključi opciju da istorija utiče na preporuku.
2. **Eksplícitno uneti podaci** — ključne reči i/ili žanrovi koje korisnik unese direktno na stranici za preporuke, nezavisno od toga da li je istorija uključena.

Izlaz iz sistema je lista konkretnih predloga filmova sa bodovima: *Recommendation(movie, score)*.

Baza znanja

Pravila su grupisana u četiri nivoa rezonovanja koji se izvršavaju redom $A1 \rightarrow A2 \rightarrow A3 \rightarrow A4$, gde svaki nivo koristi činjenice kreirane u prethodnom.

A1 — Pravila atomskih akcija

Transformišu korisnikove interakcije (iz *UserFact* i *ReviewFact*) u *KeywordInteraction* činjenice, po jednu za svaku ključnu reč filma sa kojim je korisnik interagovao:

<code>Like(User, Movie)</code>	<code>-> KeywordInteraction(User, keyword,</code>
<code>LIKE)</code>	<code>LIKE)</code>
<code>Dislike(User, Movie)</code>	<code>-> KeywordInteraction(User, keyword,</code>
<code>DISLIKE)</code>	<code>DISLIKE)</code>
<code>Review(User, Movie, value)</code>	<code>-> KeywordInteraction(User, keyword,</code>
<code>REVIEW, value)</code>	<code>REVIEW, value)</code>

A2 — Pravila evaluacije ključnih reči

Akumuliraju *KeywordInteraction* činjenice po ključnoj reči u *KeywordStats*, gde se računa težina (weight) te ključne reči:

```
weight(keyword) = (likes - dislikes) * 5 + (reviewAvg - 5) *
reviewCount
```

Oцена 5 (na skali 1–10) se smatra neutralnom — recenzije iznad nje pozitivno, a ispod nje negativno doprinose težini ključne reči.

A3 — Pravila evaluacije filmova

Filtriraju filmove koje je korisnik već pogledao. Za svaki preostali film koji sadrži bar jednu ključnu reč iz *KeywordStats*, kreira se *MovieStats* čiji je score zbir težina svih ključnih reči koje taj film sadrži.

A4 — Pravila generisanja predloga

Za svaku *MovieStats* činjenicu kreira se konačan *Recommendation(movie, score)*, uvećan bonusima:

- **+10** za svaki omiljeni žanr (*preferredGenre*) koji film sadrži,
- **+3** ako je film na korisnikovoj watchlisti.

Dva režima formiranja KeywordStats

Slojevi A1 i A2 postoje isključivo da bi se korisnikova istorija (lajkovi, nelajkovi, recenzije) pretvorila u *KeywordStats*. Sistem zato ima dva režima rada:

- **Sa uključenom istorijom** — pokreću se sva četiri sloja ($A1 \rightarrow A2 \rightarrow A3 \rightarrow A4$), a KeywordStats se gradi organski iz korisnikovih stvarnih lajkova, nelajkova i recenzija.
- **Bez istorije, sa unetim ključnim rečima** — slojevi A1 i A2 se preskaču. Za svaku ključnu reč koju je korisnik uneo direktno se ubacuje sintetička KeywordStats(keyword, likes=5, dislikes=0, reviewAvg=0, reviewCount=0), što po formuli iz A2 daje težinu 25. Pokreću se samo slojevi A3 i A4.

U oba režima, filtriranje pogledanih filmova (A3) i bonusi za omiljeni žanr i watchlistu (A4) rade na isti način, jer se oslanjaju direktno na korisnikove stvarne podatke iz UserFact, a ne na KeywordStats.

Predlaganje popularnih ključnih reči

Da bi se korisniku prilikom otvaranja stranice za preporuke ponudila lista popularnih ključnih reči, sistem ponovo koristi isti mehanizam, ograničen samo na prva dva sloja.

Za svakog korisnika u sistemu ubacuje se UserFact koji sadrži samo njegove lajkovane filmove (bez nelajkova, pogledanih, watchlist-e ili preferenci), zajedno sa MovieFact činjenicama za ceo katalog. Pokreću se isključivo slojevi A1 i A2 — bez A3 i A4, pošto ovde nije potrebno ocenjivanje pojedinačnih filmova, već samo ključnih reči. Iz radne memorije se zatim izvlače sve KeywordStats činjenice (po jedna za svakog korisnika i ključnu reč), a njihove težine se sabiraju po ključnoj reči kroz sve korisnike. Ključne reči se rangiraju po ukupnoj težini, i vraća se top N (podrazumevano 20) kao predlog.

Konkretan primer

Ulazi korisnika

- Omiljeni žanrovi: Horror, Mystery, Drama
- Watchlist: Inception
- Istorija: korisnik je lajkovao Silence of the Lambs i ostavio recenziju sa ocenom 8, i pogledao ga (watched)

Baza znanja sadrži sledeće filmove

- *Silence of the Lambs* (žanr: Horror; ključne reči: scary, horror, mystery, killer)
- *Inception* (žanr: Mystery; ključne reči: mystery, dream, suspenseful)
- *Scary Movie* (žanr: Comedy; ključne reči: scary, comedy, killer)

Primer 1 — sa uključenom istorijom

A1. Iz lajka i recenzije nad Silence of the Lambs kreiraju se interakcije za svaku od njegove 4 ključne reči (scary, horror, mystery, killer): po jedna LIKE i jedna REVIEW(8).

A2. Za svaku od te 4 ključne reči: likes=1, dislikes=0, reviewAvg=8, reviewCount=1.

```
weight = (1 - 0) * 5 + (8 - 5) * 1 = 5 + 3 = 8

KeywordStats(scary, 8), KeywordStats(horror, 8),
KeywordStats(mystery, 8), KeywordStats(killer, 8)
```

A3. Silence of the Lambs se izbacuje jer je pogledan. Od preostalih filmova:

- Inception sadrži "mystery" → MovieStats(Inception, score=8)
- Scary Movie sadrži "scary" i "killer" → MovieStats(Scary Movie, score=8+8=16)

A4. Bonusi (preferredGenres = {Horror, Mystery, Drama}, watchlist = {Inception}):

- Inception: žanr Mystery je omiljen (+10), na watchlisti je (+3) → Recommendation(Inception, score=21)
- Scary Movie: žanr Comedy nije omiljen, nije na watchlisti → Recommendation(Scary Movie, score=16)

Konačan poredak: **Inception (21) > Scary Movie (16)**

Primer 2 — bez istorije, sa unetim ključnim rečima "scary" i "mystery"

A1 i A2 se preskaču. Direktno se ubacuju:

```
KeywordStats(scary, likes=5, dislikes=0, reviewAvg=0, reviewCount=0)
-> weight = 25
KeywordStats(mystery, likes=5, dislikes=0, reviewAvg=0,
reviewCount=0) -> weight = 25
```

A3. Silence of the Lambs se i dalje izbacuje jer je pogledan (ovo se ne menja bez obzira na režim). Od preostalih:

- Inception sadrži "mystery" → MovieStats(Inception, score=25)
- Scary Movie sadrži "scary" → MovieStats(Scary Movie, score=25)

A4. Isti bonusi kao u Primeru 1:

- Inception: +10 (žanr), +3 (watchlist) → Recommendation(Inception, score=38)
- Scary Movie: bez bonusa → Recommendation(Scary Movie, score=25)

Konačan poredak: **Inception (38) > Scary Movie (25)**

Literatura

[1] Bennett, James, and Stan Lanning. "The netflix prize." Proceedings of KDD cup and workshop. Vol. 2007. 2007. Retrieved from: <https://www.cs.uic.edu/~liub/KDD-cup-2007/NetflixPrize-description.pdf>

[2] Sharma, Mugdha, Laxmi Ahuja, and Vinay Kumar. "A novel rule based data mining approach towards movie recommender system." Journal of Information and Organizational Sciences 44.1 (2020): 157-170. Retrieved from: <https://hrcak.srce.hr/file/348076>